# Обучение с экспертами для выборки со многими доменами

Н. А. Линдеманн, А. В. Грабовой

lindemann.na@phystech.edu; andriy.graboviy@mail.ru

Рассматривается задача аппроксимации multi-domain выборки единой мультимоделью — смесью экспертов. Каждый домен аппроксимируется локальной моделью. В работе рассматривается двухэтапная задача оптимизации на основе ЕМ-алгоритма. В качестве данных используется выборка отзывов сайта Amazon для разных типов товара, которая содержит в себе несколько доменов. В качестве локальной модели используется линейная модель, а в качестве признакового описания отзывов используются tf-idf вектора внутри каждого домена.

**Ключевые слова**: Смесь экспертов, локальная модель, обучение с экспертом, классификация текстов.

### 1 Введение

- На текущий момент в машинном обучении появляется все больше задач связанных с
  данными, которые взяты с разных источников. Часто появляются выборки, которые со стоят из большого количества доменов. Под доменом понимается подмножество объектов
  выборки, которые обладают некоторыми одинаковыми признаками. На текущий момент
- 6 не существует полного теоретического обоснования построения смесей локальных моделей
- 7 для аппроксимации такого рода выборок.
- В работе рассматривается задача аппроксимации multi-domain выборки единой мультимоделью – смесью экспертов, и предлагается алгоритм бинарной классификации текстов, использующий дополнительную информацию о доменах. Использование этой информации позволяет использовать более простые и интерпретируемые модели.
- Метод решения задачи состоит в построении мультимодели, являющейся смесью локальных моделей. Каждый домен аппроксимируется локальной линейной моделью, смесь которых является итоговым алгоритмом классификации. Задача обучения модели сводится к двухэтапной задаче оптимизации на основе ЕМ-алгоритма. Схема работы алгоритма представлена на рис. 1.

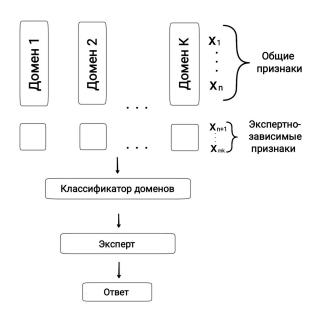


Рис. 1 Схема работы мультимодели.

В качестве данных используется выборка отзывов сайта Amazon для разных типов товара, которая содержит в себе несколько доменов. Каждый объект имеет экспертно-зависимое описание, которое определяется его пренадлежностью к тому или иному домену. В качестве признакового описания отзывов используется tf-idf вектора внутри каждого домена.

## 2 Постановка задачи

#### 2.1 Постановка задачи обучнения одного эксперта

Задача бинарной классификации является задачей апроксимации целевой функции

$$\mathbf{f}: \mathbb{R}^n \to \{-1, +1\},$$

где  $\mathbb{R}^n$  – пространство признакового описания объектов, а  $\{-1,+1\}$  – метка класса объекта. Задачей локальной модели является апроксимация функции  $\mathbf{f}$  на некотором домене. На основе общих признаков  $(x_1,\ldots,x_n)$  эксперт генерирует экспертно-зависимые признаки  $(x_{n+1},\ldots,x_{m_k})$ , количество которых зависит от конкретного домена, и с помощью признаков  $(x_1,\ldots,x_nx_{n+1},\ldots,x_{m_k})$  локальная модель делает предсказание о принадлежности объекта к одному из двух классов.

В качестве локальной модели будем использовать логистическую регрессию, которая будет предсказывать вероятность того, что объект с признаковым описанием  $x_i$  принадлежит классу  $y_i$ :

$$p(y = y_i \mid \boldsymbol{x_i}, \mathbf{w}) = \sigma(y_i \mathbf{w} \cdot \boldsymbol{x_i}).$$

Рассмотрим правдоподобие выборки, а именно, вероятность наблюдать данный вектор y у домена C (выборка размера N). В предположении, что объекты выборки внутри одного домена независимы и из одного распределения, получим:

$$p(\boldsymbol{y} \mid \mathbf{C}, \mathbf{w}) = \prod_{i=1}^{N} p(y = y_i \mid \boldsymbol{x_i}, \mathbf{w}).$$

40 Далее рассмотрим логарифм правдоподобия:

44

49

57

63

66

68

$$\log p\left(\boldsymbol{y}\mid\mathbf{C},\mathbf{w}\right) = \log\prod_{i=1}^{N}\sigma(y_{i}\mathbf{w}\cdot\boldsymbol{x_{i}}) = \sum_{i=1}^{N}\log\frac{1}{1+e^{-y_{i}\mathbf{w}\cdot\boldsymbol{x_{i}}}} = -\sum_{i=1}^{N}\log(1+e^{-y_{i}\mathbf{w}\cdot\boldsymbol{x_{i}}}).$$

3 Значит, в даном случае принцип максимального правдоподобия приводит к минимизации логистической функции потерь по всем объектам из данного домена:

$$\mathcal{L}(\mathbf{C}, \boldsymbol{y}, \mathbf{w}) = \sum_{i=1}^{N} \log(1 + e^{-y_i \mathbf{w} \cdot \boldsymbol{x_i}}) \rightarrow \min_{\mathbf{w}}.$$

#### 

Обобщим подход аппроксимации одного домена на случай, когда в данных присутствует несколько доменов. Пусть всего имеется K доменов в выборке, тогда всю выборку  ${\bf C}$  можно представить в виде:

$$\mathbf{C} = \bigsqcup_{k=1}^{K} \mathbf{C}_k',$$

где  $\mathbf{C}_k'$  множество объектов, принадлежащих k-му домену. Множеству объектов из домена  $\mathbf{C}_k' \subset \mathbf{C}$  соответствует задача линейной регрессии для выборки  $\mathbf{X}_k' \subset \mathbf{X}, \mathbf{y}_k' \subset \mathbf{y}$ . Модель  $\mathbf{g}_k$  аппроксимирующая выборку  $\mathbf{X}_k', \mathbf{y}_k'$  является локальной моделью для выборки  $\mathbf{X}_k, \mathbf{y}_k'$  является локальной моделью для выборки  $\mathbf{X}_k, \mathbf{y}_k'$ 

<sup>54</sup> Определение 1. Модель  ${\bf g}$  называется локальной моделью для выборки  ${\bf U}$ , если  ${\bf g}$  апроксимирует некоторое не пустое подмножество  ${\bf U}'\subset {\bf U}$ .

**определение 2.** Мультимодель **f** называется смесью экспертов, если:

$$\mathbf{f} = \sum_{k=1}^{K} \pi_k \mathbf{g}_k(\mathbf{w}_k), \qquad \pi_k(\mathbf{x}, \mathbf{V}) : \mathbb{R}^{n \times |\mathbf{V}|} \to [0, 1], \qquad \sum_{k=1}^{K} \pi_k(\mathbf{x}, \mathbf{V}) = 1,$$

где  $\mathbf{g}_k$  является k-й локальной моделью,  $\pi_k$  — шлюзовая функция, вектор  $\mathbf{w}_k$  является параметрами k-й локальной моделью, а  $\mathbf{V}$  — параметры шлюзовой функции.

Пусть  $\mathbf{w}_k$  является случайным вектором, который задается плотностью распределения  $p^k(\mathbf{w}_k)$ . Получим совместное распределения параметров локальных моделей и вектора ответов:

$$p(\mathbf{y}, \mathbf{W}|\mathbf{X}, \mathbf{V}) = \prod_{i=1}^{N} \left( \sum_{k=1}^{K} \pi_k p_k(y_i|\mathbf{w}_k, \mathbf{x}_i) \right),$$

64 где  $\mathbf{W} = \{\mathbf{w}_1, \mathbf{w}_2, \cdots, \mathbf{w}_K\}$ . Оптимальные параметры находятся при помощи максимиза-65 ции правдоподобия:

$$\hat{\mathbf{V}}, \hat{\mathbf{W}} = \arg \max_{\mathbf{V}, \mathbf{W}} p(\mathbf{y}, \mathbf{W} | \mathbf{X}, \mathbf{V}).$$

## 3 Вычислительный эксперимент

В качестве первого вычислительного эксперимента использовался метод из работы [5].

## Литература

o [1] J. Jiang. A Literature Survey on Domain Adaptation of Statistical Classifiers //?????, 2007

79

- 71 [2] A.B. Грабовой, B.B. Стрижов. Анализ выбора априорного распределения для смеси экспертов // ?????, 2018
- [3] G. Wilson, D.J. Cook. A Survey of Unsupervised Deep Domain Adaptation // ACM Transactions
  on Intelligent Systems and Technology, 2020
- [4] M. Wang, W. Deng. Deep Visual Domain Adaptation: A Survey // Manuscript accepted by
  Neurocomputing, 2018
- [5] J. Guo, D.J. Shah, R. Barzilay. Multi-Source Domain Adaptation with Mixture of Experts //
  Conference on Empirical Methods in Natural Language Processing, 2018

Поступила в редакцию